

Hvordan Kan AI Bli Bedre til å Forstå Tekster?

Gormery K. Wanjiru
MA223, Universitetet i Oslo
November 2024

Bakgrunn

Dette prosjektet handler om hvordan vi kan gjøre kunstig intelligens (AI) bedre til å forstå og klassifisere tekster. Vi vil vite hva som er viktigst for å forbedre nøyaktigheten til AI-modeller, særlig når det gjelder tekster om energi.

Forutsigelser

Vi brukte modellene til å forutsi hvor godt de vil fungere på nye tekster:

- **Forventet Nøyaktighet:** 75.2% nøyaktighet for nye tekster.
- **Usikkerhet:** Vi tror nøyaktigheten vil ligge mellom 58.1% og 92.3%.

Hypotese

Vi tror at større datasett og enklere tekster vil gjøre AI-modellen mer nøyaktig. Valg av modell er mindre viktig enn størrelsen på datasettet og hvor komplisert teksten er.

Datainnsamling

Vi samlet tekster fra åpne kilder som Kaggle. Tekstene var av forskjellig lengde og vanskelighetsgrad:

- **Korte tekster:** 100-200 ord
- **Middels tekster:** 500-700 ord
- **Lange tekster:** Over 1000 ord

Vanskelighetsgraden ble vurdert ut fra lengden på setningene og antallet vanskelige ord.

Hva Vi Gjorde

Vi brukte to metoder for å analysere dataene:

- **Regresjon:** For å se hvordan datasettstørrelse, tekstvanskelighet og modell påvirker nøyaktigheten.
- **Bayesiansk Analyse:** For å forstå hvor usikker modellen er, og hvordan den kan prestere på nye tekster.

Resultater

Hva Var Viktigst?

Vi fant ut at disse faktorene var viktigst for modellens ytelse:

- **Tekstvanskelighet:** Tekster som er vanskelige, gjør modellen mindre nøyaktig.
- **Datasettstørrelse:** Jo mer data vi har, desto bedre blir modellen.
- **Valg av Modell:** BERT-modellen var mest nøyaktig, men det var mindre viktig enn størrelsen på datasettet eller tekstvanskeligheten.

Hvorfor Er Dette Viktig?

Hvis vi kan gjøre AI bedre til å forstå tekster, kan vi få bedre kunde-service, automatiske sammendrag, og hjelp til studier. Det er viktig å fokusere på gode data og mye data for å få dette til.

Oppsummering

Hva Fant Vi Ut?

- **Større datasett** gir bedre resultater.
- **Enklere tekster** gjør modellen mer nøyaktig.
- **Valg av modell** hjelper litt, men ikke like mye som datasettstørrelse og tekstvanskelighet.