

Optimalisering av Tekstklassifisering: Hvordan Datasett, Kompleksitet og Modeller Påvirker AI-en's Presisjon

Gormery K. Wanjiru

MA223
Oslo, 5. oktober 2024

1 Innledning

Målet med dette prosjektet er å undersøke hvordan ulike faktorer påvirker ytelsen til enkle maskinlæringsalgoritmer for tekstklassifisering. Vi ønsker å se nærmere på hvordan faktorer som datasettstørrelse, tekstens kompleksitet, og valg av modell påvirker nøyaktigheten til en tekstklassifiseringsmodell. Ved å hente data fra åpne kilder på internett, kan vi få innsikt i hvordan man kan forbedre maskinlæringsmodeller for tekstanalyse, for eksempel ved sentimentanalyse eller klassifisering av dokumenter.

2 Datasamling

Vi planlegger å samle inn data ved å bruke åpne datasett fra kjente kilder som Kaggle og andre tilgjengelige tekstdatasett for klassifisering. Dataene vil inkludere tekster med varierende lengde og kompleksitet, samt datasett av ulike størrelser. Vi vil også sette noen felle tekst for den. Dette vil gi oss et godt grunnlag for å identifisere hvordan disse faktorene påvirker modellens ytelse. Bare for å begrense oss, Hva som teller som suksess er at den klarer å finne ting som er relevant for et fornybær energi selkap.

3 Analysere Data

3.1 Målinger og prosess

De innsamlede dataene vil gi oss informasjon om hvordan faktorer som datasettstørrelse, tekstens kompleksitet, og valg av maskinlæringsmodell påvirker nøyaktigheten til en tekstklassifiseringsmodell. For dette prosjektet vil vi bruke maskinlæringsverktøy som Scikit-learn, BERT eller TensorFlow for å trene modellen og evaluere ytelsen. Vi vil også analysere effekten av ulike modelltyper. Vi kan også bare bruke ferdig trent modeller og bare se effekten av de forskjellige faktorer.

3.2 Parametere

Vi vil beregne nøyaktigheten til modellen under de forskjellige forholdene, variasjoner i ytelse basert på datasettstørrelse og tekstens kompleksitet, og korrelasjonen mellom valg av modell og modellens nøyaktighet.

3.3 Prediktivt

Vi planlegger å bruke prediktiv modellering for å estimere hvordan endringer i datasettstørrelse, tekstens kompleksitet, eller valg av modell kan påvirke ytelsen i fremtiden. Dette vil gi oss innsikt i hvordan man best kan optimalisere treningsprosessen for å oppnå bedre nøyaktighet i tekstklassifisering.

3.4 Hypotesetest

Vi vil utføre hypotesetester for å undersøke om endringer i datasettstørrelse, tekstens kompleksitet eller valg av modell er statistisk signifikante for nøyaktigheten til tekstklassifiseringsmodellen. Dette vil gi en vitenskapelig basis for å påvise hvordan ulike faktorer påvirker ytelsen til maskinlæringsmodeller for tekstklassifisering.

4 Data kilder

Vi vil hente dataene fra åpne datasett på internett, som inkluderer tekstdatasett fra Kaggle og andre tilgjengelige kilder. Dette vil sikre at vi har et bredt og representativt bilde av hvordan ulike faktorer påvirker ytelsen til maskinlæringsmodeller for tekstklassifisering.

5 Analyseverktøy

For dataanalyse vil vi bruke Python med biblioteker som Scikit-learn, TensorFlow, eller Keras for maskinlæring, samt R for statistiske analyser og datavisualisering. Excel vil brukes til å organisere de første dataene og lage enkle oversikter. Python og R vil bli benyttet til mer avanserte analyser, som regresjonsanalyse og prediktiv modellering, samt til å lage grafiske fremstillinger av resultatene.

6 Forventede Resultater

Vi forventer å finne en tydelig sammenheng mellom faktorer som datasettstørrelse, tekstens kompleksitet, og valg av modell og ytelsen til maskinlæringsmodeller for tekstklassifisering i energisektoren. Dette vil gi innsikt i hvilke faktorer som har størst påvirkning på modellens nøyaktighet, og hvordan man kan tilrettelegge for optimal trening av maskinlæringsmodeller for energirelatert tekstanalyse. Prosjektet vil gi en bedre forståelse av hvordan ulike faktorer påvirker ytelsen til tekstklassifiseringsmodeller og hvordan man kan forbedre nøyaktigheten for anvendelser som kundekommunikasjon, energiforbruksanalyse, og hovedsaklig klassifisering av tekniske dokumenter innen energibransjen.