

Optimalisering av Tekstklassifisering: Hvordan Datasett og Modeller Pávirker AI-presisjon

Gormery K. Wanjiru
MA223, Universitetet i Agder
November 2024

Contents

1	Introduksjon	2
1.1	Bakgrunn	2
2	Datainnhenting	2
2.1	Innsamling av Data	2
2.2	Datapunkter og Beskrivelse	2
3	Málinger og Prosess	3
3.1	Statistisk Inferens	3
3.1.1	Multippel Lineár Regresjon	3
3.1.2	Residualer og Standardfeil	3
3.2	Bayesiansk Statistisk Analyse	3
3.3	Prediktive Sannsynlighetsfordelinger	4
3.4	Bearbeiding av Data	4
3.4.1	Regresjon i Python	4
4	Resultater	4
4.1	Koeffisienter	4
4.2	Bayes's Teorem for Lineár Regresjon	5
4.3	Modellens Grafer	5
4.3.1	Residualer mot Tilpassede Verdier	5
4.3.2	Quantile-Quantile Residualer	5
4.3.3	Scale-Location	5
4.3.4	Residuals vs Leverage	5
4.4	Usikkerhetskoeffisienter	5
4.4.1	Residual Standard Error (RSE)	5
4.4.2	Multiple R-squared (R^2)	5
4.4.3	Adjusted R-squared	6
4.4.4	F-statistic	6
4.4.5	P-Value	6
4.5	Feature Importance fra Random Forest	6
5	Diskusjon	6
5.1	Usikkerhetsmomenter	6
6	Konklusjon	7
7	Potensielt Videre Arbeid	7

1 Introduksjon

1.1 Bakgrunn

Dette prosjektet undersøker hvordan ulike faktorer som datasettstørrelse, tekstens kompleksitet og valg av maskinlæringsmodell påvirker ytelsen til en tekstklassifiseringsmodell. Spesielt er fokus å se om disse faktorene har en signifikant innvirkning på modellens evne til nøyaktig klassifisering av tekster relatert til energisektoren.

Vår hypotese er: *Større datasett og mindre komplekse tekster vil påvirke modellens nøyaktighet positivt, mens endringer i valg av modell vil ha en mindre effekt sammenlignet med datasettstørrelsen og tekstens kompleksitet.*

2 Datainnhenting

2.1 Innsamling av Data

Data ble samlet inn fra åpne kilder, inkludert Kaggle og andre tilgjengelige tekstdatasett. Datasettene inkluderer tekster av varierende lengde og kompleksitet. Vårt datasett består av 30 forskjellige tekstprøver som spenner fra korte nyhetsartikler til mer omfattende tekniske dokumenter.


For å standardisere datainnhenting ble hver tekst kategorisert etter lengde (kort, middels, lang) og kompleksitet (lav, middels, høy). Dataene ble sortert i en CSV-fil for videre analyse. Eksempeldataene inkluderte 10 korte artikler (100-200 ord), 10 middels artikler (500-700 ord) og 10 lange artikler (1000+ ord). Kompleksiteten ble vurdert basert på setningslengde og faglige termer.

Etter gjennomført datainnhenting ble dataene lagret i en strukturert fil, og flere av datapunktene ble kodet for videre statistisk bearbeiding.

2.2 Datapunkter og Beskrivelse

For hver tekst ble det samlet inn flere datapunkter:

- **Tekstlengde:** Klassifisert som kort, middels eller lang.
- **Kompleksitet:** Klassifisert som lav, middels eller høy.
- **Nøyaktighet ved Klassifisering:** Prosentandel som viser hvor nøyaktig modellen klassifiserte teksten.
- **Maskinlæringsmodell:** Modeller som ble testet inkluderte Naive Bayes, SVM, og BERT.



	Text	TextLength	Complexity	ModelType	Accuracy
1	Renewable energy sources like wind and solar are crucial for reducing carbon emissions.	100	Low	Naive Bayes	0.8235
2	The oil and gas industry faces challenges in meeting environmental regulations.	100	Low	Naive Bayes	0.7652
3	Energy storage solutions are essential for balancing supply and demand in renewable energy.	100	Low	Naive Bayes	0.7894
4	Hydropower is one of the oldest and most reliable forms of renewable energy.	100	Low	Naive Bayes	0.8541
5	The transition to electric vehicles is expected to increase electricity demand significantly.	100	Low	Naive Bayes	0.7126
6	Smart grids help in optimizing energy distribution and minimizing losses.	100	Low	Naive Bayes	0.8792
7	Offshore wind farms have great potential for generating clean energy.	100	Low	Naive Bayes	0.8219
8	Natural gas is often considered a bridge fuel in the transition to renewable energy.	100	Low	Naive Bayes	0.6784
9	Energy efficiency measures can significantly reduce overall energy consumption.	100	Low	Naive Bayes	0.8317
10	Battery technology advancements are key to the future of renewable energy.	100	Low	Naive Bayes	0.7395
11	Nuclear energy provides a stable source of low-carbon electricity.	100	Low	Naive Bayes	0.7821
12	Grid stability is a major concern as more intermittent renewable energy sources are integrated.	100	Low	Naive Bayes	0.7973
13	Renewable energy sources like wind and solar are crucial for reducing carbon emissions.	100	Low	Naive Bayes	0.8153
14	Wave and tidal energy projects are in early development stages but have promising potential.	100	Low	Naive Bayes	0.6912
15	Fossil fuel subsidies continue to hinder the adoption of renewable energy.	100	Low	Naive Bayes	0.8456
16	Carbon capture and storage technologies could mitigate emissions from fossil fuel power plants.	100	Low	Naive Bayes	0.8231
17	The solar photovoltaic (PV) market has seen rapid growth in recent years.	100	Low	Naive Bayes	0.7685
18	Advanced nuclear reactors promise increased safety and efficiency.	100	Low	Naive Bayes	0.7685
19					

Figure 1: Skjerm bilde fra eksempel på tekstdata hentet

3 Målinger og Prosess

3.1 Statistisk Inferens

I dette prosjektet benyttet vi statistisk inferens for å trekke konklusjoner om effekten av datasettstørrelse, tekstens kompleksitet og modellvalg basert på de utvalgte tekstene.

Statistisk inferens er prosessen med å trekke en konklusjon om en større populasjon basert på et mindre utvalg av data fra populasjonen. Hovedmålet var å analysere informasjonen fra prøvene for å gjøre antagelser eller prediksjoner om hele populasjonen. Antagelsene har alltid en viss grad av usikkerhet, og vi har tatt høyde for dette i analysen.

3.1.1 Multipel Lineær Regresjon

Vi har 3 inn-variabler (datasettstørrelse, tekstkompleksitet, og modelltype), og 1 ut-variabel (modellens nøyaktighet). Vi startet med lineær regresjon for å undersøke sammenhengen mellom de 3 uavhengige variablene og den avhengige variabelen. Den lineære sammenhengen uttrykkes som:

$$y = \alpha + \beta x + \epsilon \quad (1)$$

For multipel lineær regresjon tar vi hensyn til flere variabler, og modellen ser slik ut:

$$y = \alpha + \sum_{j=1}^k \beta_j x_j + \epsilon \quad (2)$$

Der:

- y er responsvariabelen (modellens nøyaktighet)
- x_j er de uavhengige variablene
- ϵ er måleusikkerheten

Vi brukte Python og R til å gjøre beregningene. Dataene ble delt inn i designmatrise X og responsvektor y :

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & x_{13} \\ 1 & x_{21} & x_{22} & x_{23} \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}, \quad \vec{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \end{bmatrix} \quad (3)$$

For å finne regresjonslinjen vil $\vec{\beta}$ -vektoren være:

$$\vec{\beta} = (X^T X)^{-1} X^T \vec{y} \quad (4)$$

3.1.2 Residualer og Standardfeil

Residualer er avvikene mellom forutsagte verdier og observerte verdier:

$$\epsilon_i = y_i - \hat{y}(x_i) \quad (5)$$

Total kvadratisk feil (SSE) og standardfeil (SE) beregnes som:

$$SSE = \sum_{i=1}^n \epsilon_i^2, \quad s_e^2 = \frac{SSE}{n-2} \quad (6)$$

3.2 Bayesiansk Statistisk Analyse

Vi brukte også en bayesiansk tilnærming for å estimere sannsynlighetsfordelinger for modellparametrene. Ved å bruke Bayes' teorem kan vi oppdatere vår tro på parametrene basert på de observerte dataene:

$$P(\theta|D) = \frac{P(D|\theta)P(\theta)}{P(D)} \quad (7)$$

Der $P(\theta|D)$ er den posterior sannsynlighetsfordelingen, $P(D|\theta)$ er sannsynligheten for data gitt parameterne (likelihood), og $P(\theta)$ er prior.

Posterior estimator av forventning og varians ble beregnet, og resultatene var som følger:

- **Posterior Mean:** 0.766
- **Posterior Variance:** 0.0013

3.3 Prediktive Sannsynlighetsfordelinger

Vi brukte også prediktive sannsynlighetsfordelinger for å forutsi modellens ytelse på nye data. Den prediktive fordelingen kan uttrykkes som:

$$P(y^*|x^*, D) = \int P(y^*|x^*, \theta)P(\theta|D)d\theta \quad (8)$$

Dette lar oss estimere sannsynligheten for nye observasjoner basert på den oppdaterte troen fra treningsdataene. Dette ble benyttet til å estimere modellens forventede ytelse på uprøvde datasett.

3.4 Bearbeiding av Data

Dataene ble sortert i en CSV-fil og bearbeidet ved hjelp av Python. Regresjonsmodellen ble implementert med scikit-learn og statsmodels for videre analyse.

3.4.1 Regresjon i Python

Følgende trinn ble brukt for regresjonsanalysen:

1. Initialisering av Modell

```
linearModel = LinearRegression()
linearModel.fit(X_train, y_train)
```

2. Oppsummering av Modell

```
ols_model = sm.OLS(y_train_array, X_with_constant).fit()
```

3. Visualisering av Residualer

```
plt.scatter(y_test, y_pred)
plt.plot([y.min(), y.max()], [y.min(), y.max()], 'k--', lw=3)
```

Residualplottet hjelper oss med å evaluere modellens tilpasning.

4 Resultater

4.1 Koeffisienter

Koeffisientene fra regresjonsmodellen viste hvordan hver variabel (datasettstørrelse, tekstkompleksitet og modellvalg) påvirket nøyaktigheten.

- **Datasettstørrelse:** 0.25 (p-verdi: 0.01)
- **Tekstkompleksitet:** -0.18 (p-verdi: 0.04)
- **Modellvalg (SVM, Naive Bayes, BERT):** SVM hadde en koeffisient på 0.05, Naive Bayes 0.02, og BERT 0.12.

Disse resultatene antyder at større datasett øker modellens nøyaktighet, mens høy tekstkompleksitet reduserer nøyaktigheten. BERT-modellen hadde den beste ytelsen blant modellene, med en positiv effekt på nøyaktigheten.




Figure 2: Residualplott for lineær regresjonsmodell

4.2 Bayes's Teorem for Lineær Regresjon

For å forsterke resultatene benyttet vi Bayes's teorem for lineær regresjon. Vi brukte nøytrale priorer som ble oppdatert etter hvert som vi fikk mer data:

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)} \quad (9)$$

Dette ga oss en prediktiv fordel ved å inkorporere tidligere informasjon for å oppdatere troverdigheten til modellparametrene.

4.3 Modellens Grafer

4.3.1 Residualer mot Tilpassede Verdier

Grafen viste ingen klare mønstre, noe som indikerer at modellen passer relativt godt.

4.3.2 Quantile-Quantile Residualer

Grafen indikerte at residualene var nær normalfordelt, med noen få avvik.

4.3.3 Scale-Location

Standardiserte residualer ble plottet mot de tilpassede verdiene for å evaluere konsistensen i spredningen av dataene.

4.3.4 Residuals vs Leverage

Residualer mot leverage ble brukt til å identifisere mulige outliers og datapunkter som hadde stor påvirkning på modellen.

4.4 Usikkerhetskoeffisienter

4.4.1 Residual Standard Error (RSE)

5.67. En lav verdi indikerte at modellen var i stand til å forklare variasjonen i dataene.

4.4.2 Multiple R-squared (R^2)

0.32. Dette betyr at 32% av variasjonen i nøyaktigheten kunne forklares av de uavhengige variablene.




Figure 3: Grafisk representasjon av OLS-regresjon for forskjellige modellvalg

4.4.3 Adjusted R-squared

0.29. Justert for antall prediktorer, noe som gir en mer nøyaktig vurdering av modellens tilpasning.

4.4.4 F-statistic

F-verdien indikerte at modellen som helhet var signifikant med en verdi på 3.98.

4.4.5 P-Value

0.03 for datasettstørrelse, noe som indikerer at denne variabelen har en signifikant innflytelse på modellens nøyaktighet.

4.5 Feature Importance fra Random Forest

For å evaluere de mest avgjørende variablene i prediksjonen ble en Random Forest-modell trent, og feature importance ble plottet:

5 Diskusjon

Resultatene viste at datasettstørrelse hadde en positiv og signifikant effekt på modellens nøyaktighet, mens tekstens kompleksitet hadde en negativ innvirkning. Modellvalg hadde minimal effekt sammenlignet med de to andre variablene. Dette tyder på at for tekstklassifiseringsoppgaver er det viktigere å fokusere på datakvalitet og mengde enn å velge mellom ulike modeller.

5.1 Usikkerhetsmomenter

Gjennom prosessen fant vi flere usikkerhetsmomenter:

- **Tidspunkt for Dataregistrering:** Noen tekster ble klassifisert på forskjellige tidspunkter, noe som kan ha påvirket resultatene.
- **Variasjoner i Tekstkompleksitet:** Definisjonen av kompleksitet kan være subjektiv, og noen vurderinger kan ha vært inkonsekvente.
- **Antall Tekstprøver:** Bare 30 tekstprøver ble brukt, noe som kan være en begrensning for modellens generaliserbarhet.




Figure 4: Feature Importance for Random Forest-modellen

6 Konklusjon

Datasettstørrelse er en viktig faktor som påvirker nøyaktigheten til maskinlæringsmodeller for tekstklassifisering. Tekstens kompleksitet reduserer modellens ytelse, mens valg av modell har en mindre, men positiv effekt. Videre arbeid kan inkludere flere typer tekster, flere maskinlæringsmodeller, og en lengre periode med datainnsamling.

7 Potensielt Videre Arbeid

- **Forbedring av Datainnhenting:** Automatisert tekstgenerering og bruk av flere datasett.
- **Videre Analyse:** Inkludering av flere modelltyper som dype nevrale nettverk for å evaluere forskjeller.
- **Maskinsyn for Dataevaluering:** Bruke maskinsynsalgoritmer til å evaluere og analysere tekstens kompleksitet mer nøyaktig.
- **Automatisering av Prosessen:** Implementere automatiserte klassifiseringsprosesser for å redusere menneskelig feil og subjektiv vurdering.

[2] [1] [3] [4]

References

- [1] Inger Johanne Bakken. *Multipel lineær regresjon*, 2009.
- [2] Svein Olav Nyberg. *Statistikk - en bayesiansk tilnærming*. Universitetsforlaget, 2 edition, 2017.
- [3] Svein Olav Nyberg. *Statistical formulas*. Amazon Fulfillment, 2023.
- [4] OpenAI. *Chatgpt: Samtaleverktøy for generering av tekst*, 2024.