
Statistikk-prosjektet

Statistikk-prosjektet er en del av mappevurderingen for karakter i MA-223, og teller 30%. Type prosjekt faller for det aller meste innenfor en av tre hovedkategorier:

1. Analysere data
2. Stokastisk simulering
3. Podcast / Journalistikk

Det er stor oppfinnsomhet blandt studenter, så det er mulig å gå utenfor disse rammene, eller å krysse mellom to. I slike tilfelle bør dere snakke med faglærer, for å få satt rammer og kriterier for hva akkurat dere skal gjøre.

Innhold

0.1	Karakter	1
0.2	Forprosjekt	2
0.3	Samle data og simulere	2
1	De tre prosjekt-typene	2
2	Analysere data	3
2.1	Målinger og prosess	3
2.2	Parametere	4
2.3	Predikativt	5
2.4	Hypotesetest 1: Sammenligning mot fast verdi	5
2.5	Hypotesetest 2: Sammenligning av parametere	5
2.6	Intervallestimat	6
2.7	Illustrasjoner	6
2.8	Oppbygning og hva som skal med	6
2.9	Slutten: Vedlegg. Utregninger, R -kode, og grunnlagsdata	6
2.10	"Men hva skal jeg skrive prosjekt om?"	7
3	Simulering	8
3.1	Hva kreves av et simulerings-prosjekt?	8
4	Podcast	9
4.1	Hva kreves av et podcast-prosjekt?	9

0.1 Karakter

For første gang er prosjektet i MA223 karaktertellende. Da er det greit å kjenne kriteriene for karakter.

-
- Gruppestørrelse. Et prosjekt som for en 3-medlemmers gruppe får A, vil kunne få C for en gruppe på 5. Vi setter poeng på de forskjellige elementene, og deler på gruppestørrelse.
 - A3-poster. Alle prosjekter, uansett type, skal lage en A3-poster der de presenterer hva de har gjort.
 - Maskinskrevet rapport. For alle prosjekter unntatt podcast er dette hoved-delen av prosjektet.
 - Originalitet, relevans, interesse. Nøkkelen for alle tre er å undersøke rundt et tema du faktisk har interesse av å finne ut om.
 - Statistiske metoder. I hvor stor grad gjør dere bruk av det dere har lært? Prosjekter som kun er datainnsamling+presentasjon er F. Så sørg for å bruke inferens (kap. 11-17) i boka og/eller relevante simuleringer.
 - Metoder utenfor pensum. Dersom undersøkelsene deres leder dere utenfor pensum, hvor dere bruker metoder utover det som er undervist, vil denne ekstra innsatsen bli godt belønnet. Disse elementene teller også for punktet over.
 - Evne til fremstilling. Samme undersøkelse kan bli godt og dårlig beskrevet og forklart. Det gir forskjellig karakter.
 - Diagrammer, illustrasjoner, bilder. Dette hører inn under fremstilling. En god fremstilling har gode og relevante bilder.

0.2 Forprosjekt

Gå sammen i grupper på ideelt 3-4 personer (max 5, min 1), og lag en forprosjektrapport som forteller hva dere har lyst til å finne ut, hvordan dere skal utføre målingene, og hva dere ønsker å finne ut om universet utover målingene deres. Forprosjektet er ikke obligatorisk, men gjør det enkelt å få en systematisk tilbakemelding på prosjektet mens det er underveis.

0.3 Samle data og simulere


Hvor mange datapunkter trenger dere for å få en tilstrekkelig skarp konklusjon? Eller hvor mange runder og hvor mange lag med simulering må til? Sørg for å sette av tid nok til dette. Spør gjerne underveis.

1 De tre prosjekt-typene

De tre prosjekt-typene er som sagt (1) Analysere data, (2) Stokastisk simulering, og (3) Podcast / Journalistikk.

2 Analyser data

For analyse av data er det aller viktigste å huske, dette: Målingene deres betyr *nesten* ingen ting. Det er konklusjonene om den underliggende stokastiske prosessen (inferens) og om mulige fremtidige data som betyr noe.



I dette diagrammet er den lille lilla øya dataene som er samlet inn. De er ikke ingenting, men kan vi ikke si noe om det som er utenfor den øya, så som det blå eller grønne området, så har vi ikke gjort universitetsnivå statistikk, og vi har kun klart å si noe om noen bittesmå % eller %₀ av det som er.

2.1 Målinger og prosess

Det første dere må klarlegge er slags type data dere skal se på. Vi skal i løpet av semesteret lære oss om *prosesser* for de forskjellige typene data, og de bruker vi for å gjøre selve analysen. Men alt dere trenger å gjøre i første omgang, er å bestemme dere for typen data. Dere bør måle samme slags verdier for *to* alternativer. Fx to typer bjelke, to typer hus, to politiske partier, osv.

- **Boolske** verdier (Ja/Nei-svar): Tell antall positive ($k \top$) og antall negative ($l \perp$). **Prosess: Bernoulli.**
- **Ventestørrelser:** Måling av forekomster (n) over en tid/strekning/areal/volum/ ... (t), eventuelt ventetid/volum/... mellom forekomster. **Prosess: Poisson.**
- **Målestørrelser:** Måling av uavhengige skalare verdier (x) som lengde, vekt, bruddstyrke. **Prosess: Gaussisk.**

-
- **Sammenhengende verdier:** Her ser dere etter sammenhengen mellom to størrelser x og y (eller flere). Dere samler inn tallpar (x, y) , og analyserer disse. **Prosess: Regresjon.**

- Den vanligste sammenhengen er lineær regresjon (x og y er skalarer, og sammenhengen er en rett linje). Da skal dere først bruke metodene fra kapittel 3 og deretter analysere usikkerhet med metodene fra kapittel 17. Eksempel: x = tykkelse på bjelke, y = bruddstyrke på bjelken. Du finner da ut hvor mye tykkelsen påvirker bruddstyrken gjennom formelen $y = a + bx$ (kap 3), og hvor mye usikkerhet det er i dette anslaget (kap 17).
- Logistisk regresjon (x er skalar, y er boolsk, og sammenhengen er en logistisk kurve). Dette er ikke dekket i pensum, men er spennende oppgaver som kan løses i **R**. Dere får hjelp underveis. Eksempel: x = regnmengde siste 3 dager, y = skogbrann(Ja/Nei). Du finner da ut hvor mye regnmengden påvirker sannsynligheten for skogbrann.

Dette er valg det er mulig å ta allerede etter første dag med MA223.

2.2 Parametere

Når data og forprosjekt er på plass, venter vi på å komme til de riktige kapitlene i **Inferens-**delen av pensum. Kap. 13 og utover. Det første dere gjør i denne delen, er å finne deres prosess, og parameterne som beskriver denne prosessen.

Dere kobler data og parametere sammen ved å regne ut (kap. 13 og 17) *posterior hyperparametre* for sannsynlighetsfordelingene som beskriver parameterne, og deretter sannsynlighetsfordelingene for parameterne. Det vanligste vil være å bruke *nøytrale* prior hyperparametere, men det er absolutt ingenting feil med å lage seg *informative* prior hyperparametere i stedet.

- Bernoulli: $p_1 \sim \beta_{(\theta_1, \rho_1)}$ og $p_2 \sim \beta_{(\theta_2, \rho_2)}$.
- Poisson: $\lambda_1 \sim \gamma_{(k_1, \tau_1)}$ og $\lambda_2 \sim \gamma_{(k_2, \tau_2)}$.
- Gaussisk: $\mu_1 \sim t_{(m_1, s_1)}$ og $\frac{1}{\sigma_1^2} = \tau_1 \sim \gamma_{(k_1, \lambda_1)}$ for den første, og $\mu_2 \sim t_{(m_2, s_2)}$ og $\frac{1}{\sigma_2^2} = \tau_2 \sim \gamma_{(k_2, \lambda_2)}$ for den andre.
- Lineær Regresjon: Finn en t -fordeling for stigningstallet b , og en γ -fordeling for $\tau = \frac{1}{\sigma^2}$. Du finner også en ganske stor formel for en t -fordeling med avhengighet av x selve regresjonslinjen $y(x)$.
- For logistisk og andre mer eksotiske former for regresjon, bruk **R** og lær fortolkning av output for R. Denne fortolkningen skal sammen med oppsummerende output fra R være en del av rapporten din.

2.3 Prediktivt

Dernest kan dere finne prediktiv fordeling ut fra de posterior hyperparameterne.

- Bernoulli: Her kan dere finne sannsynlighetsfordelingen for enten
 - antall $\top$ i løpet av et fiksert antall forsøk, n . (beta-binomisk)
 - antall $\perp$ før et fiksert antall suksesser $\top$, k . (beta-negativ binomisk)
- Poisson: Her kan dere finne sannsynlighetsfordelingen for enten
 - antall forekomster k i løpet av en fiksert tidsperiode T . (negativ binomisk)
 - tiden T som trengs for et fiksert antall forekomster, k . (gamma-gamma)
- Gaussisk: Her kan dere finne sannsynlighetsfordelingen for X_+ , altså verdien til neste måling.
- Regresjon: Neste observasjon Y_+ , gitt en spesifisert x -verdi. Her vil ikke Y_+ være bare et tall, men en sannsynlighetsfordeling. Sjekk prediktiv sannsynlighetsfordeling for et par spesifiserte x -verdier. For *lineær* regresjon vil denne være nokså lik sannsynlighetsfordelingen for regresjonslinjen $y(x)$. For logistisk regresjon må dere kode litt i R for å få et plott.

2.4 Hypotesetest 1: Sammenligning mot fast verdi

Noen ganger kan det være aktuelt å sammenligne en parameter θ mot en konstant referanseverdi θ_0 , altså med H_1 enten at $\theta > \theta_0$ eller H_1 enten at $\theta < \theta_0$. Typisk da er

- Bernoulli: sammenligne parameter π mot konstant referanseverdi π_0 .
- Poisson: sammenligne parameter λ mot konstant referanseverdi λ_0 .
- Gaussisk 1: sammenligne parameter μ mot konstant referanseverdi μ_0 .
- Gaussisk 1: sammenligne parameter σ mot konstant referanseverdi σ_0 . (eller da i stedet for σ bruke $\tau = \frac{1}{\sigma^2}$)

Du regner da ut sannsynligheten for H_1 som motsetning H_0 , og måler $P(H_0)$ mot *signifikansen* α , og trekker konklusjon. Du kan plukke α (helst mindre enn 0.2) fra løse luften, eller du kan regne den ut etter instruksjonene i læreboka som $\alpha = \frac{w_1}{w_0 + w_1}$ (og da kan den være hva som helst, for begrunnelsen er der!).

2.5 Hypotesetest 2: Sammenligning av parametere

Som hypotesetest 1, men sammenligning av to parametre mot hverandre, altså θ_1 mot θ_2 , ved å se på de respektive sannsynlighetsfordelingene.

- Bernoulli: $P(p_1 > p_2)$. De kan også sammenlignes mot et fast referansetall π .

-
- Poisson: $P(\lambda_1 > \lambda_2)$. De kan også sammenlignes mot et fast referansetall L .
 - Gaussisk 1: $P(\mu_1 > \mu_2)$
 - Gaussisk 2: $P(\tau_1 > \tau_2) = P(\sigma_1 < \sigma_2)$.

2.6 Intervallestimat

Alle parameterne egner seg til intervalestimat. Det vanligste er 2-sidige $P\%$ intervalestimat, men HPD-intervaller er også helt OK. Dere velger P selv.

Noen av de prediktive verdiene egner seg også til intervalestimat, men det er enklest for de kontinuerlige. For regresjon blir intervalestimatene til kurver.

2.7 Illustrasjoner

Tegn opp noen av sannsynlighetsfordelingene. Velg selv hvilke som er viktigst. Dette kan være lurt å gjøre i sammenheng med enten hypotesetest eller intervalestimat, for å illustrere disse.

2.8 Oppbygning og hva som skal med

- Begynn rapporten med motivasjon for hvorfor dere ville undersøke akkurat dette. Følg gjerne opp med en kort beskrivelse av datainnsamlingen. Her passer det med bilder av dere selv, utstyr, det dere observerte, og evt andre bilder dere synes passer inn.
- Deretter kommer resultatene, men da rett på konklusjonene, altså: hyperparameterne, sannsynlighetsfordelingene, intervalestimatene og sammenligningene, og illustrasjonene av sannsynlighetsfordelingene.
- Til slutt refleksjon rundt hva dere lærte om temaet i prosjektet, og kanskje også refleksjoner rundt hva dere gjorde riktig underveis, men også om ting dere ville gjort annerledes neste gang.
- Eventuelt. Alle prosjekter er unike. Noen krever ting som ikke er i standardmalen, og dette kan dere både flette inn underveis, eller dere kan legge det som eget punkt til nesten-slutt.

Mange bekymrer seg for å ikke skrive lang nok rapport. Ingen fare! For deres egen del kan dere bruke som guideline 5 sider med normal størrelse på skrift, bilder og layout. Det som teller, er at dere har fått med dere punktene over, ikke hvor mye papir det tok.

2.9 Slutten: Vedlegg. Utregninger, R-kode, og grunnlagsdata

Med noen hederlige unntak, så skal disse legges i vedleggsdelen av rapporten (roterommet bakerst). Rapporten skal stå på egne bein og kunne forklare hva dere har gjort uten disse elementene. De er med i vedlegget kun for de som vil dykke dypere ned i materialet.

2.10 ”Men hva skal jeg skrive prosjekt om?”

Alt som kan telles og måles kan gjøres til gjenstand for statistikk! Så den beste angrepsmåten er å

1. se om det er noe du kunne tenkt deg å finne ut
2. deretter se om det er noe du kan måle i forbindelse med det du vil finne ut
3. først deretter sjekke hva slags prosess du har
4. og hvis du ikke finner prosess, spørre faglærer om det kan lages prosjekt av det du ville finne ut likevel

Det er den *beste* måten, og det kan ikke vektlegges tungt nok! Men om du fremdeles er i tvil, eller om alt du ønsket i livet var å få en oppskrift og å koke et prosjekt etter den, så er det rom for det òg. Da kan du se på noen eksempler på prosjekter her:

- **Bernoulli/Boolsk:**

- Seiere i fotball. Hver kamp er ett forsøk i en Bernoulli-prosess. Sammenlign to lag over en sesong.
- Feilproduksjon. Hver produserte enhet er et forsøk. Feilproduksjon eller ikke. Dette kan gjøres hjemme, hvor produksjonen kan være alt fra muffins til perfekt maling av husvegg. Sammenlign to slike produksjonslinjer.
- Virkning av annonse. Positiv reaksjon på annonsen er å klikke på den, eller positivt kryss i direkte undersøkelse. Hver undersøkelse av reaksjon er ett forsøk. Sammenlign to forskjellige annonser for samme, eller for forskjellige produkt.
- Starte gammel motorsag. La det være litt tid mellom hvert forsøk på å starte, så start-forsøkene er uavhengige. Sammenlign to motorsager.

- **Poisson/Venteverdier:**

- Antall mål over en eller flere fotballkamper. n =antall mål, t =antall kamper. Sammenlign to lag over en sesong, eller sammenlign mål inn og mål ut.
- Antall løvtrær i et gitt areal skog. n =antall løvtrær, t =arealet du har telt over. Sammenlign to skogsområder.
- Antall hvitveis innen strekke-seg-avstand langs en sti. n =antall hvitveis, t =lengde tilbakelagt. Sammenlign stier i to forskjellige områder.
- Besøke call center og notere antall innkommende samtaler n over en viss observasjonsperiode t . Sammenligne to sentere, eller to forskjellige dager.
- Sile gjennom spillvann og finne mynter. La n være antall mynter og t være volumet spillvann. Sammenlign spillvann i to forskjellige byer.

- **Gaussisk/Størrelser:**

- Ballbesittelse. Prosentene fra hver kamp er en måling. Sammenlign to lag over en sesong.

-
- Omkrets på voksne trær i et skogsområde. Sammenlign to skogsområder.
 - Kraft som trengs for å knekke en pinne. Sammenlign to typer pinne.
 - Strømforbruk per husholdning i en by. Hver husholdning er et målepunkt. Sammenlign to byer ved å sample noen husholdninger fra hver by.
 - Strekking av seigmenn. Lengden hver seigmann ryker på er målingen. Sammenlign to seigmann-merker.
 - Antall sykler en komponent tåler før den ryker. Selv om dette er et heltall, så er antallet så stort at gaussisk prosess er den beste tilnærmingen. Antall sykler for 1 komponent er en måling. Sammenligne to forskjellige typer komponenter.
 - Måle kondensatorer på $100\mu F$. Hver kondensator gir da en måling. Sammenligne $100\mu F$ -kondensatorer av to forskjellige merker.
- **Lineær regresjon (sammenheng mellom skalare x og y):**
 - x =kvadratmeter grunnflate, y =strømforbruk
 - x =slagvolum på motor, y =drivstofforbruk over en viss fastsatt strekning
 - x =tykkelse på bjelke av fiksert bredde og lengde, y =kraft for å knekke bjelken
 - x =omkrets på tre, y =høyden til treet
 - **Logistisk regresjon (sammenheng mellom skalar x og boolsk y):**
 - x =antall innbyggere i internasjonal by, y =har egen opera?
 - x =antall smilende ansikter i en reklame, y =klikker på linken i reklamen?
 - x =BMI, y =har diabetes?
 - x =inntekt sist år, y =har fått fartsbot siste året?
 - x =anslått kostnad på prosjekt, y =overskridelse?

3 Simulering

Simuleringsoppgaver prøver ut flere scenarier, og gjør statistikk på resultatene av et stort antall simuleringer gjort på basis av en sannsynlighetsfordeling for fremtidige utkommer. Basisen for simuleringene kan ofte være reelle data. For eksempel kan du bruke sesongene 2019,2020,2021 og 2022 for et ballspill eller annen konkurranseport som basis for å simulere utkomme i 2023 eller en fremtidig sesong.

3.1 Hva kreves av et simulerings-prosjekt?

- Koden for simuleringen må enten være selvskreivet, eller være en egentilpasning av kode dere referer til i rapporten. Kvalitet og tydelig egeninnsats er det som er vurderingskriteriene for simuleringsprosjekter.
- For simuleringsprosjekter skal det også leveres komplette kjørbare kodefiler, og også her gis det poeng for om kjøringen i seg selv kan gi noe underveis, for eksempel i form av levende grafer som oppdaterer seg.

-
- Koden skal følge god programmeringspraksis, med gode variabelnavn, struktur, og kommentar i selve koden.
 - Prosjektet skal også inneholde en seksjon som beskriver og forklarer koden, og der det har vært flere mulige valg, hvorfor dette valget fremfor andre.

4 Podcast

Podcast er en type prosjekt som gir stor frihet. Første gang det ble åpnet for denne typen prosjekt var våren 2022. Podcastene skal være faglig relevante, og publiseres på Canvas og andre egnede media for at medstudenter og eventuelt andre interesserte skal kunne høre på.

4.1 Hva kreves av et podcast-prosjekt?

- Podcastene skal være statistikk-relevante. Men innenfor dette er det stor frihet. Mulige tema:
 - Forklar eller ha samtale om et vanskelig statistikk-tema på en måte som gjør at lytteren skjønner mer om temaet etter podcasten.
 - Intervjuer med statistikere. Fx intervju Arnold Frigessi om hans modellering av covid-spredning, eller Fred Espen Benth om hvordan han bruker sannsynlighet for å modellere aksjemarkedet.
 - Reportasje(r) om hvordan statistikk brukes innenfor ditt fagområde.
 - Samtaler med folk i gata om dere forhold til statistikk, hvor dere selv oppsummerer samtalene på slutten av episoden.
- Et svært viktig element for podcast-prosjekter er *refleksjon - i alle ledd*.
- *Deres A3-plakat skal inneholde korte beskrivelser av hver av episodene.*
- *Rapport. For dere skal denne være kort, og er essensielt A3-plakaten pluss ting dere ikke fikk plass til på plakaten. Vi vil gjerne at dere har med:*
 - *Refleksjon over hva dere har lært.*
 - *Skriftlig lytterundersøkelse. Denne trenger ikke være på mange ord.*
- *Dere kan i tillegg til den skriftlige lytterundersøkelsen ha en av podcast-episode med, for, eller om lytterundersøkelsen.*