

Ikke dårlig vær, bare dårlige studenter

av

Maren Valand, Max Høigilt, Arle Vaara og Alexander Ruud

i

MA 223

Statistikk

Fakultet for teknologi og realfag

Universitetet i Agder

Grimstad, Mars/April/Mai 2024

Innhold

1	Introduksjon	3
1.1	Bakgrunn	3
2	Datainnhenting	3
3	Målinger og prosess	4
3.1	Statistisk inferens	4
3.1.1	Multippel lineær regresjon	4
3.1.2	Residualer og standardfeil	4
3.2	Bearbeiding av data	5
3.2.1	Regresjon i R	5
4	Resultater	6
4.1	Koeffisienter	6
4.2	Bayes's teorem for lineær regresjon	6
4.3	Modellens Grafer	7
4.3.1	Residualer mot Tilpassede verdier	7
4.3.2	Quantile-Quantile Residualer	8
4.3.3	Scale-Location	8
4.3.4	Residuals vs Leverage	9
4.4	Usikkerhetskoeffisienter	9
4.4.1	Residual Standard Error (RSE)	9
4.4.2	Multiple R-squared (R^2)	9
4.4.3	Adjusted R-squared	9
4.4.4	F-statistic	9
4.4.5	P-Value	10
4.5	Usikkerhetsmomenter	10
4.5.1	Tidspunktet for telling	10
4.5.2	Ulike synsvinkler	10
4.5.3	Tidsrom	10
4.5.4	Antall bilder per dag	10
4.5.5	Obligatorisk oppmøte	10
5	Konklusjon	11
5.1	Hva kunne blitt gjort bedre?	11
5.2	Potensielt videre arbeid	11

1 Introduksjon

Vær har tilsynelatende stor innvirkning på menneskers daglige liv og atferd. I landbruk kan været være avgjørende for en god avling og inntekt, men har været så stor innvirkning på valgene vi tar i hverdagen? ”Ikke dårlig vær, bare dårlige klær” er et kjent uttrykk man bruker når det er dårlig vær, men vitner ikke det til at vi lar oss styre av været?

I vårt prosjekt skal vi se på værmeldingens potensielle påvirkning på studenters oppmøte på universitetet. Gjennom å analysere data om skoleoppmøte i ulike værforhold, vil vi utforske om det er en signifikant forskjell i antall studenter til stede på skolen avhengig av været. Vi vil undersøke om oppmøtet varierer betydelig når det er regn, sol, vind eller andre værforhold. Ved hjelp av statistisk analyse søker vi å avdekke om det er en pålitelig sammenheng mellom vær og oppmøte på skolen, og hvordan disse forholdene kan påvirke antall studenter som møter opp på skolen hver dag.

Vår hypotese lyder som dette: *’Dårlig vær’ påvirker negativt på hvor mange som oppholder seg på campus. Nedbør påvirker oppmøte mer enn vind og temperatur.*

1.1 Bakgrunn


Vi var interessert i å se om det faktisk er noen statistisk sammenheng med dårlig vær og oppmøte da egne erfaringer gjerne antyder at dette kan være tilfelle. Oppmøte på campus oppleves veldig varierende, og dersom vær spiller en signifikant rolle, vil det kanskje kunne si noe om studenters prioriteringer og dedikasjon. Vi har ikke funnet noe forskning eller statistikk på dette.

2 Datainnhenting

Våre data består av registreringer av regn, vind og temperatur for en gitt dag, samt en telling av oppmøte på campus rundt lunsjtid for å se om værmeldingen har hatt innvirkning på oppmøtet.

Værdata ble hentet kvelden før dagen tellebilder ble tatt. Det var en fast person til å ta tellebilder i kantina, og en annen til å telle antall personer i bildet. Vi valgte å gjøre det sånn for å redusere ulikheter i telling, og for å sikre relativt lik bilde kvalitet. Vi hadde også oppsatt fast tidspunkt, både til bildetaking, og til innhenting av værdata.

Etter gjennomført data innhenting hadde vi 30 registreringer av vær, samt 30 tellebilder fra kantina. .csv fil med data som vi legger med som vedlegg.



Figur 1: Screenshot fra yr for vær 31.januar

Figur 2: Tellebilde fra kantina

Figur 3: Eksempelbilder fra datainnhenting

3 Målinger og prosess

3.1 Statistisk inferens

I dette prosjektet har vi sett på ett lite utvalg som forhåpentligvis skal kunne si noe om en større populasjon. Statistisk inferens er prosessen med å trekke en konklusjon om en større populasjon basert på et mindre utvalg av data fra den gitte populasjonen [1, Side 283]. Hovedmålet er å analysere prøveinformasjonen for å gjøre antagelser eller gjøre predikasjoner om populasjonen. Antagelsene vil alltid ha en viss grad for usikkerhet som også må tas hensyn til.

3.1.1 Multippel lineær regresjon

Vi har 3 inn-variabler(temp, vind og nedbør), og 1 ut-variabel (pers), og tar utgangspunkt i lineær regresjon for å se på en mulig sammenheng mellom disse. Vi skal med andre ord se på hvordan de 3 uavhengige variabler kan påvirker 1 avhengig variabel. Lineær regresjon er at en forklaringsvariabel x og responsvariabel y har en lineær sammenheng som blir uttrykt som dette:

$$y = \alpha + \beta x + \epsilon \quad (1)$$

ϵ viser til usikkerheten, eller målestøy. Det vil si at det vil aldri være mulig å predikere helt sikkert med regresjonslinja y [1, Side 54].

For multippel lineær regresjon må man ta hensyn til flere variabler. Da må linja se ut som dette[2]:

$$y = \alpha + \sum_{j=1}^k \beta_j x_j + \epsilon \quad (2)$$

Med ett datasett som skal representere både x og y må vi finne α og β for å finne regresjonslinja [1, Side 56]. Vi bruker R for å gjøre utregningene, men en annen måte å gjøre det på er ved matriseregresjon. Måldata vil da bli delt inn i *design matrise* x , og *respons vektor* y [1, Side 407].

Design matrise X og Respons vektor y :

$$X = \begin{bmatrix} 1 & temp & vind & nedbør \\ \dots & \dots & \dots & \dots \\ 1 & x_n & x_n & x_n \end{bmatrix} \vec{y} = \begin{bmatrix} pers \\ \dots \\ y_n \end{bmatrix} \quad (3)$$

For å da videre finne regresjonslinjen vil β -vektor være;

$$\vec{\beta} = \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = (X^T X)^{-1} \cdot X^T \vec{y} \quad (4)$$

3.1.2 Residualer og standardfeil

Residualer og standardfeil er avvik mellom forutsagte verdier og målte verdier [1, Side 59].

Feil/residual for måling i :

$$\epsilon_i = y_i - \hat{y}(x_i) \quad (5)$$

Total kvadratisk feil, og total kvadratisk feil for lineær regresjon:

$$SS_e = \sum_{i=1}^n \epsilon_i^2 \rightarrow s_e^2 = \frac{SS_e}{n-2} \quad (6)$$

3.2 Bearbeiding av data

Vi sorterte samlede data i en .csv fil, og brukte R for å bearbeide dataene.

3.2.1 Regresjon i R

Vi fulgte Computer regression i Kap 14 i formel boka for utregningene [3, Side 40], og fremgang for lineær regresjon i R fra R-manualen, begge utarbeidet av Nyberg [4].

1. $linearModel = lm(y \sim x)$

- R har en funksjon $lm()$ som vi bruker for å gjøre beregninger på en avhengig variabel y .

2. $modelSummary = summary(linearModel)$

- $summary$ funksjonen gir oss en oppsummering på hva $lm()$ finner. Det innebærer residualer, koeffisienter, residuale standard error og mer.


3. $\vec{\beta} = (\alpha, \beta) = modelSummary\$coefficients[1 : 5]$

- Her tar vi informasjonen om koeffisientene til $\vec{\beta}$

4. $SS_e = (n - length(beta_vector)) * fitSum\$sigma^2$

- Total kvadratisk feil, avstanden mellom målt og forutsagt verdi [1, Side 404]

Med denne fremgangen kan vi lese α og β verdier og residualer mellom hvert punkt og selve regresjonslinjen.



Figur 4: Regresjonslinjen. x_wind2 er vindkast, y = antall personer

4 Resultater

Etter en tilnærmet to måneders periode med registrering av værd data og telling av studenter på campus, satt vi igjen med ca 30 målinger. Vi unngikk å gjøre målinger på dager vi antok lite oppmøte på campus (helg, helligdager, ferier og lign). Vi har aktivt brukt ChatGPT for å få enkle forklaringer på de ulike begrepene i dette kapittelet [5].

4.1 Koeffisienter

Koeffisientene sier noe om den estimerte effekten av hver uavhengige variabel på den avhengige variabelen.

Coefficients:					
	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	144.845	16.088	9.003	2.55e-09	***
data\$wind	-17.877	12.153	-1.471	0.154	
data\$wind_2	10.026	6.566	1.527	0.139	
data\$temp	-2.163	2.836	-0.763	0.453	
data\$rain	-1.369	2.200	-0.622	0.539	

Figur 5: Koeffisienter. Intercept er antall personer og wind2 er vindkast.

Estimatet representerer den beregnede koeffisienten for hver prediktor i modellen. Det angir hvor mye responsvariabelen endres når den tilsvarende prediktoren økes med én enhet, mens alle andre prediktorer holdes konstante. Et positivt estimat indikerer en positiv sammenheng mellom prediktoren og responsvariabelen, mens et negativt estimat indikerer en negativ sammenheng.

Standardfeil er et mål på usikkerheten i estimatet for koeffisienten. Det indikerer hvor mye estimatet kan variere fra prøve til prøve. Lavere standardfeil indikerer større nøyaktighet og tillit til estimatet for koeffisienten.

T-verdien/Variabilitet beregnes som kvoten av estimatet for koeffisienten og standardfeilen. Den indikerer hvor mange standardavvik estimatet ligger fra null. En høy absoluttverdi av t-verdien tyder på at koeffisienten er signifikant forskjellig fra null.

P-verdien er sannsynligheten for å observere en t-verdi som er like ekstrem eller mer ekstrem enn den observerte, under nullhypotesen om at koeffisienten er null. En lav p-verdi (typisk mindre enn 0.05) indikerer at koeffisienten er signifikant forskjellig fra null, og at prediktoren er statistisk signifikant i modellen.

4.2 Bayes's teorem for lineær regresjon

Vi har brukt nøytrale priorere, som betyr at $v_0 = -2$ og $SS_0 = 0$ [3, Side 41].

$$\begin{aligned} P_1 | \bar{x} &= \frac{\sum x}{n} \\ \vec{\beta} &= \begin{bmatrix} \alpha \\ \beta \end{bmatrix} \\ v_1 &= v_0 + n = -2 + 30 \\ SS_1 &= SS_0 + SS_e \end{aligned} \tag{7}$$

Ut fra utregningene i R, finner vi at $\vec{\beta}$ blir som dette:

$$\vec{\beta} = \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = 144.845156, -2.163203, -17.876502, 10.025623, -1.369393 \tag{8}$$


Vi ser også fra utregningene i 3.2.1 at vi finner SS_e .

$$SS_1 = SS_0 + SS_e = 0 + 36025.68 \quad (9)$$

Med dette kan vi oppdatere posterior verdier. Ettersom det har vist seg å være liten til ingen sammenheng mellom vær og oppmøte vil en prediksjon trolig ikke være troverdig.

4.3 Modellens Grafer


4.3.1 Residualer mot Tilpassede verdier



Figur 6: Plot av Residual vs fitted

Grafen i figur 6 viser residualene mot de tilpassede verdiene. Tilpassede verdier er verdiene som kommer fra regresjonsmodellen. Residualer er differansen mellom observerte verdier og tilsvarende tilpassede verdier. Grafen er ment til å se etter mønster i den røde linjen eller avvikende verdier. Ideelt sett ligger mesteparten av verdiene rundt den stiplede grå linjen på 0.


4.3.2 Quantile-Quantile Residualer



Figur 7: Plot av Q-Q residuals

Grafen i figur 7 viser hvordan residualene er fordelt, sammenlignet med en ren normalfordeling. Den grå stiplede linjen representerer en ideell normalfordeling. Enkeltplokk som ikke følger linjen er avvik, mens flere kan vise til at residualene ikke er normalfordelte.


4.3.3 Scale-Location



Figur 8: Plot av scale-location

Standardiserte residualer er et mål på hvor mange standardavvik en observasjon er i fra regresjonslinjen, eller modellen. Scale-Location grafen i figur 8 viser kvadratroten av standardiserte residualer mot tilpassede verdier. Ideelt sett er verdiene fordelt sporadisk rundt en horisontal linje. En traktformet fordeling eller en som ikke er konstant tyder på ulik spredning.

4.3.4 Residuals vs Leverage



Figur 9: Plot av residuals vs leverage

Grafen i figur 8 viser residualene mot tyngden til hver observasjon. Meningen med grafen er å kunne se etter enkeltmålinger som påvirker resultatet for mye i forhold til resten. Ideelt sett er det få avvik, hvor ingen målinger har både høy tyngde og store residualer.

4.4 Usikkerhetskoeffisienter

Usikkerhetskoeffisientene man får i resultatet av en multippel lineær regresjon gir informasjon om den statistiske signifikansen til de individuelle predikatorene.

4.4.1 Residual Standard Error (RSE)

Dette er estimatet for standardavviket til feilene i modellen. Det måler hvor mye responsvariabelen varierer rundt den sanne regresjonslinjen. Lavere verdier av RSE indikerer en bedre tilpasning av modellen til dataene. RSE i modellen er 37.96, på 25 graders frihet. Dette kan sammenlignes med gjennomsnittsmålet til responsvariabelen, som er 136.7.

4.4.2 Multiple R-squared (R^2)

Dette er kvadratet av korrelasjonskoeffisienten mellom den observerte responsvariabelen og den predikerte responsvariabelen fra modellen. R^2 måler hvor mye variasjon i responsvariabelen som forklares av predikatorene i modellen. Verdier av R^2 varierer mellom 0 og 1, der 1 indikerer en perfekt tilpasning av modellen til dataene. R^2 i modellen er 0.138.

4.4.3 Adjusted R-squared

Dette er en justert versjon av R^2 som tar hensyn til antall prediktorer i modellen og antall observasjoner i datasettet. Justert R^2 er mer konservativ enn R^2 og straffer tilførsel av unødvendige prediktorer i modellen. Det er et bedre mål på modellens generaliserbarhet til nye data. Adjusted R-squared i modellen er $6.009e - 05$.

4.4.4 F-statistic

Dette er en statistisk test som evaluerer om minst én av predikatorene i modellen har en signifikant effekt på responsvariabelen. Det er forholdet mellom variansen til predikert respons og variansen til den ubetingede

modellen (dvs. modellen uten prediktorer). En høy F-verdi, sammen med en liten p-verdi assosiert med den, indikerer at modellen som helhet er signifikant. F-statistics i modellen er 1 på 4, og 25 DF.

4.4.5 P-Value

P-verdien er et mål på hvor sannsynlig det er å observere dataene gitt at nullhypotesen er sann. Nullhypotesen sier at predikatorene ikke har noen effekt på responsvariabelen. P-verdien hjelper med å vurdere om resultatene er statistisk signifikante, og en lav p-verdi (≤ 0.05) indikerer at det er en signifikant sammenheng. P verdien i modellen er 0.4259.

```
Residual standard error: 37.96 on 25 degrees of freedom
Multiple R-squared:  0.138,    Adjusted R-squared:  6.009e-05
F-statistic:      1 on 4 and 25 DF,  p-value: 0.4259
```

Figur 10: Output fra *summary* om usikkerhetskoeffisienter

4.5 Usikkerhetsmomenter

Gjennom prosessen fant vi flere usikkerheter knyttet til målingen av dataen til prosjektet.

4.5.1 Tidspunktet for telling

Tidspunkter for når bilde ble tatt varierte alt fra mellom 12 til 14. Dette er en faktor som har påvirket resultat vårt i og med at det er færre studenter på ved kantine området etter 13.

4.5.2 Ulike synsvinkler

For å telle antall personer ble et bilde tatt av skoleområdet. Bilde ble som oftest tatt av samme person med samme kamera, men ikke hele tiden. Av og til ble bildet tatt av ulike personer, og kameravinkelen (m.t.p. retning) kan ha vært ulik fra bilde til bilde. Enkelte bilder kan også ha blitt tatt med Ulike innstillinger for vinkelen på linsen.

4.5.3 Tidsrom

Tidsrommet som ble valgt strakk seg over omtrent én måned. Det kan hende modellen hadde vært bedre om det hadde vært en god del flere målinger.

4.5.4 Antall bilder per dag

Det er ikke eksakt like mange bilder for hver ukedag. Vi har ikke tatt bilder på hellig- og fridager, og enkelte dager ble det ved feiltagelse ikke tatt bilder. Dette kan i liten grad påvirke resultatet.

4.5.5 Obligatorisk oppmøte

Studenter har eksamener, prøver, obligatoriske forelesninger eller start/slutt på praksisperioder som gjør at enkelte dager kan gjøre at antallet er mye høyere eller lavere enn det skal være.

5 Konklusjon

Formålet med dette prosjektet var å se på en mulig sammenheng mellom værforhold og oppmøte av studenter på campus.

Gjennom våre observasjoner har vi sett at det er liten sammenheng mellom antall personer som møter opp på campus og værforhold. Vi har målt over et begrenset tidsrom (omtrent én måned) og vi har kun observert oppmøte på et bestemt område av campus. Dette har gjort det vanskelig å konkludere med en direkte sammenheng er at det er flere variabler som vi ikke har tatt hensyn til, f. eks. forelesningerplaner.

Grafene i kapittel 4.3 viser til en stor spredning i fordelingen og noen få avvik. Usikkerhetskoeffisientene viser til en redusert statistisk signifikans. Dette er basert på en Multiple R-Squared på 0.138, Adjusted R-Squared på $6.009e - 05$ og en F-statistic på 1 på 4. En lav P-verdi indikerer også statistisk signifikans, men den er 0.4259 i denne modellen.

Selv om resultatet sier at det ikke er noen sammenheng mellom responsvariabel og predikatorene, sier også noen av koeffisientene at modellen ikke er statistisk signifikant. Det kan bety at den statistiske analysen ikke er dekkende nok for å finne et signifikant resultat. Videre arbeid kunne utføres for å få økt statistisk signifikans.

5.1 Hva kunne blitt gjort bedre?

Som vi skriver om i under usikkerhetsmomentene i kapittel 4.5 er både tidpunkt for telling, bilde vinkel og antall bilder noe som kunne blitt gjennomført bedre. Automatisering av av telleprosessen kunne også vært med å skaffet data som var mer 'likt' innhentet. Under datainnhentingen noterte vi ned oss hvilken dag dataene ble hentet inn på. Ifølge analysen var dette av større signifikans enn været for å se sammenheng med oppmøte, så dette kunne vært av interesse å sett nærmere på til ett annet prosjekt.

5.2 Potensielt videre arbeid

Fremtidige muligheter kan inkludere:

- Vurdering av muligheten for å installere kamera med timer (selv om GDPR-kompatibilitet er en bekymring). Dette kunne gi bedre kontroll på bildeopptakene ved spesifikke tidspunkter og fra samme vinkel hver gang.
- Analyse av forelesningsplaner for å identifisere andre mulige påvirkende faktorer på studenters oppmøte.
- Undersøkelse av kantinetilbud og dets innvirkning på antall personer til stede. Er det mulig at kantina tiltrekker flere studenter på bestemte dager basert på menyen?
- Øke frekvensen av bildetaking og telling til to eller tre ganger daglig på ulike tidspunkter, i stedet for kun én gang daglig kl. 12.
- Revurdere metoden for å telle personer på skolen eller stedet for telling. Kanskje kunne vi ha vurdert å implementere en sensor som måler antall personer som går inn og ut av hovedinngangen for mer nøyaktig datainnsamling.

Referanser

- [1] Svein Olav Nyberg. *Statistikk - en bayesiansk tilnærming*. Universitetsforlaget, 2.opplag 2017.
- [2] Inger Johanne Bakken. *Multippel lineær regresjon*. Published: 2009. URL: <chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://folk.ntnu.no/slyderse/medstat/KLMED8005/Multreg2009.pdf>.
- [3] Svein Olav Nyberg. *Statistical formulas*. Amazon Fulfillment, 2023.
- [4] Svein Olav Nyberg. «R-Manual». I: (). URL: <chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/http://bayesians.net/no/redskaper/guides/R.pdf>.
- [5] OpenAI. *ChatGPT*. Samtaleverktøy for generering av tekst. 2023. URL: <https://openai.com/chatgpt>.